

Proiect la Probabilități și Statistică

Anul II, Calculatoare și Tehnologia Informației

Aplicații R, simulare și Shiny

Important

1. Proiectul se realizează în echipă de **2-4 persoane**. Fiecare echipă va desemna un lider, care va fi precizat în documentație.
2. Rezolvarea va fi realizată în limbajul **R**. Fiecare problema este obligatorie și valorează 15 puncte. Pentru problema a doua este necesară realizarea unei aplicații **Shiny**.
3. Fiecare echipă va trimite o **singură arhivă** la adresa **simona.cojocsa@fmi.unibuc.ro**, înainte de **30 mai 2026, ora 22:00**, care conține:
 - fișierele sursă R;
 - fișierul/fisierele aplicației Shiny;
 - documentația proiectului;
 - eventualele fișiere auxiliare necesare rulării proiectului.
4. Documentația este **obligatorie**. Lipsa documentației atrage necorectarea proiectului.
5. Documentația trebuie să conțină:
 - numele membrilor echipei și rolul fiecăruia;
 - descrierea problemei;
 - aspectele teoretice folosite;
 - precizări privind pachetele R utilizate;
 - comentarea codului și a soluției prezentate;
 - grafice, tabele și capturi relevante din aplicație;
 - prezentarea dificultăților întâmpinate, a soluțiilor găsite și a problemelor care au rămas deschise;
 - concluzii.
6. Codul sursă trebuie comentat. Nu se acceptă proiecte în care codul este trimis fără explicații.
7. Acolo unde nu sunt precizări explicite, echipele au libertatea de a face ipoteze suplimentare, cu condiția să le prezinte și să le justifice în documentație.

Problema 1. Evenimente rare: detecție și simulare

În multe situații din lumea reală, evenimentele importante apar rar: defectarea unei componente, apariția unei fraude, o eroare severă într-un sistem informatic, o zi cu trafic foarte intens, detectarea unei activități suspecte etc. Scopul acestui proiect este să construiți un studiu prin simulare în R pentru un sistem în care apar evenimente rare și să analizați cât de eficient pot fi ele detectate.

Context. Considerăm un sistem informatic care primește zilnic cereri de acces. Majoritatea cererilor sunt normale, dar o proporție mică dintre ele sunt suspecte. Sistemul folosește un mecanism simplu de verificare: nu toate cererile sunt analizate manual, ci doar o parte dintre ele, alese după anumite reguli.

Cerințe obligatorii.

1. Construiți în R un model de simulare pentru activitatea sistemului pe durata unui an calendaristic. Pentru fiecare zi se va genera:
 - numărul total de cereri de acces;
 - numărul de cereri normale;
 - numărul de cereri suspecte;
 - numărul de cereri verificate;
 - numărul de cereri suspecte detectate și respectiv nedetectate.
2. Numărul total de cereri dintr-o zi va fi generat aleator. Echipa poate alege o repartiție potrivită, de exemplu Poisson, normală trunchiată, binomială negativă sau o combinație de repartiții, dar alegerea trebuie justificată.
3. Probabilitatea ca o cerere să fie suspectă trebuie să fie mică, de exemplu între 0.1% și 2%. Studiați cel puțin trei scenarii:

$$p = 0.001, \quad p = 0.005, \quad p = 0.02.$$

4. Implementați cel puțin două strategii de verificare:
 - a) verificare aleatoare simplă: se verifică un procent fix din cererile zilnice;
 - b) verificare adaptivă: în zilele cu număr mare de cereri se verifică un procent mai mare;
 - c) opțional, o strategie propusă de echipă.
5. Pentru fiecare strategie calculați:
 - probabilitatea empirică de a detecta cel puțin o cerere suspectă într-o zi;
 - proporția medie de cereri suspecte detectate;
 - proporția medie de cereri suspecte nedetectate;
 - numărul mediu de verificări efectuate zilnic;
 - un indicator de eficiență, ales și definit de echipă.

Problema 1. Evenimente rare: detecție și simulare – continuare

6. Reprezentați grafic rezultatele:

- histograma numărului de cereri suspecte pe zi;
- histograma numărului de cereri suspecte detectate;
- grafic comparativ între strategiile de verificare;
- evoluția zilnică a cererilor suspecte și a celor detectate.

7. Studiați prin simulare efectul creșterii numărului de verificări. Pentru mai multe procente de verificare, de exemplu

1%, 5%, 10%, 20%, 30%,

determinați cum se modifică probabilitatea de detecție.

8. Formulați o concluzie practică: care strategie este mai bună și în ce sens? Este suficient să verificăm aleator un procent mic din cereri sau este necesară o strategie adaptivă?

Cerințe ulterioare

1. Introduceți un cost pentru verificarea unei cereri și un cost pentru nedetectarea unei cereri suspecte. Construiți o funcție de cost total:

$$C = c_1 \cdot \text{număr verificări} + c_2 \cdot \text{număr cereri suspecte nedetectate}.$$

Studiați care strategie minimizează costul mediu.

2. Repetați simularea de cel puțin 1000 de ori și comparați rezultatele medii cu variabilitatea lor.

3. Includeți în documentație o discuție despre diferența dintre probabilități teoretice și probabilități estimate prin simulare.

Pachete R recomandate:

- tidyverse pentru manipularea datelor;
- ggplot2 pentru reprezentări grafice;
- lubridate pentru lucrul cu date calendaristice;
- patchwork sau gridExtra pentru combinarea graficelor.

Împărțire recomandată a muncii în echipă:

- o persoană se ocupă de modelul probabilistic și justificarea repartițiilor;
- o persoană implementează simulările;
- o persoană realizează graficele și tabelele comparative;
- o persoană coordonează documentația, interpretarea rezultatelor și testarea codului.

Problema 2. Aplicație Shiny pentru transformări de variabile aleatoare continue

Scopul acestui proiect este construirea unei aplicații interactive în Shiny care permit studiul transformărilor de variabile aleatoare continue. Utilizatorul va alege o repartiție pentru o variabilă aleatoare X , va genera un eșantion, va aplica o transformare $Y = g(X)$ și va compara grafic distribuția lui X cu distribuția variabilei transformate Y . Verificați corectitudinea simulării suprapunând peste histograma densitatea de probabilitate.

Cerințe obligatorii.

1. Construiți o aplicație Shiny cu o interfață clară, care să conțină cel puțin următoarele secțiuni:

- alegerea repartiției lui X ;
- alegerea parametrilor repartiției;
- alegerea dimensiunii eșantionului n ;
- alegerea transformării g ;
- afișarea histogramelor;
- afișarea unor indicatori numerici.

2. Aplicația trebuie să permită alegerea a cel puțin patru repartiții continue:

$$\mathcal{N}(\mu, \sigma^2), \quad \text{Exp}(\lambda), \quad \text{Unif}(a, b), \quad \text{Gamma}(\alpha, \theta).$$

Pentru fiecare repartiție, utilizatorul trebuie să poată modifica parametrii.

3. Pentru variabila aleatoare X , aplicația va genera un eșantion

$$X_1, X_2, \dots, X_n.$$

Se vor afișa:

- histograma valorilor generate;
- media empirică;
- dispersia empirică;
- deviația standard empirică;
- minimul, maximul și cuartilele.

4. Aplicația trebuie să permită alegerea a cel puțin cinci transformări:

$$g(x) = x^2, \quad g(x) = |x|, \quad g(x) = \log(x), \quad g(x) = e^x, \quad g(x) = \frac{1}{1 + e^{-x}}.$$

Pentru transformările care nu sunt definite pe tot suportul repartiției, aplicația trebuie să trateze corect situația. De exemplu, pentru $g(x) = \log(x)$ trebuie discutat ce se întâmplă dacă valorile generate sunt negative sau nule.

Problema 2. Aplicație Shiny pentru transformări de variabile aleatoare -continuare-

5. Pentru variabila transformată

$$Y = g(X),$$

se vor afișa:

- histograma valorilor lui Y ;
 - media empirică;
 - dispersia empirică;
 - deviația standard empirică;
 - minimul, maximul și cuartilele.
6. Aplicația trebuie să afișeze comparativ histograma lui X și histograma lui Y . Se recomandă ca acestea să fie prezentate fie una lângă alta, fie în două taburi diferite.
7. Includeți o secțiune de interpretare automată simplă, în care aplicația afișează mesaje de tipul:
- transformarea a modificat simetria distribuției;
 - transformarea a comprimat valorile mari;
 - transformarea a produs valori strict pozitive;
 - transformarea a accentuat valorile extreme.
8. Documentația trebuie să explice, pentru cel puțin două transformări, ce efect are transformarea asupra valorilor generate. De exemplu:

$$X \sim \mathcal{N}(0, 1), \quad Y = X^2$$

produce valori pozitive și este legată de repartiția χ^2 cu un grad de libertate.

Componentă bidimensională obligatorie.

Adăugați în aplicație o secțiune separată pentru transformări bidimensionale. Utilizatorul va genera două variabile aleatoare continue X și Y , apoi va construi o nouă variabilă:

$$Z = h(X, Y).$$

1. Permiteți cel puțin două variante pentru generarea perechii (X, Y) :
 - a) X și Y independente, fiecare cu repartiție aleasă de utilizator;
 - b) (X, Y) generate dintr-o repartiție normală bidimensională cu un coeficient de corelație ρ ales de utilizator.
2. Pentru cazul normal bidimensional, utilizatorul trebuie să poată modifica:

$$\mu_X, \quad \mu_Y, \quad \sigma_X, \quad \sigma_Y, \quad \rho.$$

Problema 2. Aplicație Shiny pentru transformări de variabile aleatoare – continuare

3. Aplicația trebuie să afișeze:

- un scatterplot pentru perechile generate (X_i, Y_i) ;
- histograma lui X ;
- histograma lui Y ;
- histograma variabilei transformate $Z = h(X, Y)$.

4. Implementați cel puțin patru transformări bidimensionale:

$$\begin{aligned}h(X, Y) &= X + Y, & h(X, Y) &= X - Y, & h(X, Y) &= XY, \\h(X, Y) &= \sqrt{X^2 + Y^2}.\end{aligned}$$

5. Pentru fiecare simulare bidimensională calculați:

- media empirică a lui X , Y și Z ;
- dispersia empirică a lui X , Y și Z ;
- covarianța empirică dintre X și Y ;
- coeficientul de corelație empiric dintre X și Y .

6. Comparați vizual ce se întâmplă când $\rho = 0$, $\rho = 0.5$ și $\rho = -0.5$ în cazul normal bidimensional. Includeți capturi și comentarii în documentație.

Pachete R recomandate:

- shiny pentru aplicația interactivă;
- shinydashboard sau bslib pentru organizarea interfeței;
- ggplot2 pentru grafice;
- dplyr pentru prelucrarea datelor;
- MASS sau mvtnorm pentru generarea normală bidimensională;
- plotly, opțional, pentru grafice interactive;
- DT, opțional, pentru tabele interactive.

Problema 2. Aplicație Shiny pentru transformări de variabile aleatoare – continuare

Cerințe privind aplicația Shiny.

1. Aplicația trebuie să poată fi rulată local fără erori.
2. Interfața trebuie să fie suficient de clară încât un utilizator care nu cunoaște codul să poată folosi aplicația.
3. Toate inputurile trebuie validate. De exemplu:
 - deviațiile standard trebuie să fie strict pozitive;
 - parametrul λ al repartiției exponențiale trebuie să fie strict pozitiv;
 - pentru cazul normal bidimensional trebuie să avem $-1 < \rho < 1$;
 - pentru $\log(X)$ trebuie tratate valorile pentru care transformarea nu este definită.
4. Aplicația trebuie să conțină cel puțin un buton de tip **Simulează** sau **Generează**, astfel încât simularea să nu se actualizeze haotic la fiecare modificare minoră a parametrilor.
5. Documentația trebuie să includă capturi din aplicație și explicații pentru cel puțin trei exemple concrete.

Împărțire recomandată a muncii în echipă:

- o persoană se ocupă de interfața Shiny;
- o persoană implementează generarea variabilelor aleatoare și validarea parametrilor;
- o persoană implementează transformările unidimensionale și bidimensionale;
- o persoană realizează graficele, documentația și interpretarea rezultatelor.

Bonus

Pentru oricare dintre cele două probleme, se poate obține un bonus de maximum 5 puncte pentru cerințe suplimentare relevante, de exemplu:

- o interfață Shiny avansată;
- grafice interactive sau animații;
- comparații între rezultate teoretice și rezultate empirice;
- tratarea elegantă a erorilor introduse de utilizator;
- explicații matematice clare și bine documentate.

Bonusul nu poate duce nota finală asociată laboratorului peste punctajul maxim stabilit.